

EP-STD (Environment-Prompted Spatio-Temporal Diffusion) 架构分析

项目名称: EP-STD - 环境引导的时空扩散犯罪预测模型


版本: 2.0

日期: 2026-04-13

核心目标: 解决犯罪预测中的冷启动问题 (Cold Start)

一、整体架构设计

1.1 系统概览



1.2 详细数据流图

1.3 各模块详细输入输出

1.3.1 数据预处理模块

文件	输入	输出	说明
<code>chicago_crime_downloader.py</code>	Socrata API	<code>chicago_crime_data/cleaned/*.csv</code>	下载暴力/财产犯罪数据
<code>build_static_features.py</code>	OSM数据/遥感数据	<code>data/processed/*_features.npy</code>	构建静态环境特征
<code>build_od_flow.py</code>	Divvy/Taxi CSV	<code>*_inflow_daily.npy</code> 等	日级OD流聚合
<code>grid_mapping.py</code>	10000网格OD + 1246网格	<code>*_1246.npy</code>	网格对齐映射
<code>build_crime_timeseries.py</code>	Cleaned crime CSV	<code>crime_combined_timeseries.npy</code>	(730, 1246, 2) 双犯罪类型

1.3.2 特征工程模块

文件	输入	输出	形状
<code>build_stgcn_input.py</code>	静态特征+天气+犯罪滞后	<code>X.npy</code> , <code>Y.npy</code>	X:(723,1246,44), Y:(723,1246)
<code>build_graph.py</code>	Crime时间序列+Grid	5张邻接矩阵	(1246, 1246) 或 (700, 1246, 1246)

X.npy 特征维度分解:

<code>X.shape = (T-T_lag, N, F)</code>
- <code>T-T_lag</code> : 723 天 (滞后7天)
- <code>N</code> : 1246 个网格
- <code>F</code> : 44 维特征
* <code>Spatial static</code> : 24 维 (POI+Landuse+Road+Green+Nightlight+Camera)
* <code>Weather</code> : 8 维 (7天滞后)
* <code>Crime lag</code> : 14 维 (Violent/Property × 7天滞后)

1.3.3 EP-STD 三阶段模型

Stage 1: 环境编码器 (Environment Encoder)

```
# epstd_stage1.py
Input:  static_features (N, 24)  # 静态环境特征
Output: env_embeddings (N, 64)  # 环境嵌入
        checkpoints/env_encoder_best.pt
```

Stage 2: 原型学习 (Prototype Learning)

```
# epstd_stage2.py
Input:  env_embeddings (N, 64)
Output: prototype_library.pkl      # 原型库
        prototype_labels.npy      # (N,) 每个网格的原型标签
        prototype_centers.npy     # (K, 64) K个原型中心
```

Stage 3: 多图扩散模型 (Multi-Graph Diffusion)

```
# epstd_stage3_enhanced_multigraph.py
Input:
- X_train: (samples, N, F)      # 环境特征
- Y_train: (samples, N)         # 犯罪标签
- adj_list: [A_spatial, A_distance, A_crime_v, A_crime_p, A_od]  # 5张图
- env_emb: (samples, N, 64)     # Stage 1输出
- prototype_ids: (N,)           # Stage 2输出

Output:
- risk_mean: (N,)              # 预测风险均值
- risk_std: (N,)               # 预测不确定性
- pi: (N,)                     # 零膨胀概率
- graph_weights: (5,)          # 图融合权重 (可解释性)
- crime_gate: (2,)             # 犯罪类型门控
```

二、创新方法与技术细节

2.1 核心创新点总览

创新点	传统方法	EP-STD改进	解决的问题
1. 三阶段生成式框架	判别式(STGCN)	扩散模型+环境编码	数据稀疏、零膨胀
2. 环境自适应图融合	固定图权重	$w = \text{MLP}(E_{\text{env}})$	环境异质性
3. 双犯罪交叉反馈	单一犯罪类型	Gate(Violent, Property)	冷启动转移学习
4. T-Norm逻辑引导	无领域知识	神经符号约束	专家知识融入
5. 稀疏犯罪传播图	全连接 N^2 计算	空间掩码稀疏化	计算效率

2.2 技术细节

2.2.1 环境自适应图融合

问题: 固定权重 $w = [0.5, 0.3, 0.2]$ 无法适应不同区域的图重要性差异

解决方案: 让每个网格根据环境特征学习个性化图权重

数学公式:

$$w_i = \text{extSoftmax}(\text{extMLP}(E_{env}^{(i)})/\tau)$$

其中:

- $E_{env}^{(i)} \in \mathbb{R}^{64}$: 网格 i 的环境嵌入
- MLP: $64 \rightarrow 32 \rightarrow 5$ 的神经网络
- τ : 可学习的温度参数, 控制softmax锐度
- $w_i \in \mathbb{R}^5$: 5张图的融合权重

为什么有效:

- 商业区: OD流图权重高 (人流密集)
- 居民区: 空间邻接图权重高 (近邻效应)
- 工业区: 夜间灯光图权重高 (活动模式)

适用条件:

- 静态环境特征能区分不同功能区
- 网格数量 $N > 100$ (保证MLP有足够样本学习)

2.2.2 双犯罪交叉反馈门控

问题: 暴力犯罪数据稀疏 (零膨胀90%+) , 难以学习可靠的空间模式

解决方案: 利用财产犯罪 (高频) 辅助暴力犯罪 (低频) 预测, 通过门控动态切换

数学公式:

$$\begin{aligned} g_i &= \text{Softmax}(\text{MLP}([E_{env}^{(i)}, \bar{c}_v^{(i)}, \bar{c}_p^{(i)}])) \\ \bar{c}_v^{(i)} &= \frac{1}{T} \sum_t c_v(t, i) \quad (\text{暴力犯罪历史均值}) \\ \bar{c}_p^{(i)} &= \frac{1}{T} \sum_t c_p(t, i) \quad (\text{财产犯罪历史均值}) \\ A_{crime}^{(i)} &= g_i^{(v)} \cdot A_{crime_v} + g_i^{(p)} \cdot A_{crime_p} \end{aligned}$$

冷启动增强:

当检测到暴力犯罪稀疏时 ($\bar{c}_v^{(i)} < \epsilon$) , 强制门控偏向财产犯罪:

$$g_i = [0.3, 0.7] \quad \text{if } \bar{c}_v^{(i)} < 0.1$$

为什么有效:

- 财产犯罪与暴力犯罪在空间分布上有相关性 (如商业区两者都高)
- 财产犯罪数据密集, 空间模式更稳定
- 门控机制允许模型学习"何时依赖哪种犯罪类型"

假设条件:

- 两种犯罪类型在空间上不是完全独立 (存在相关性)
- 财产犯罪的时空模式对暴力犯罪有预测价值

2.2.3 T-Norm软逻辑引导

问题: 纯数据驱动模型在冷启动区域预测趋近于0 (历史均值) , 忽略环境风险信号

解决方案: 将犯罪学专家规则转化为可微损失函数, 在去噪过程中提供梯度引导

核心规则:

商业高 $\wedge$ 监控低 $\rightarrow$ 高风险

T-Norm转换:

- 合取 (AND) : $T(a, b) = a \cdot b$ (乘积T-Norm)
- 蕴涵 ($\rightarrow$) : $I(a, b) = \min(1, b/a)$ (Goguen蕴涵)

逻辑损失:

$$\mathcal{L}_{logic} = \underbrace{I(f_{risk}, \hat{y})}_{\text{漏报惩罚}} + \underbrace{I(1 - f_{risk}, 1 - \hat{y})}_{\text{误报惩罚}}$$

其中 f_{risk} 是从环境特征计算的风险先验:

$$f_{risk} = \sigma(w_{comm} \cdot f_{comm} + w_{road} \cdot f_{road} - w_{light} \cdot f_{light} - w_{cam} \cdot f_{cam})$$

Classifier Guidance去噪:

$$x_{t-1} = x_t - \eta[\epsilon_{\theta}(x_t, t, c) + \omega \nabla_{x_t} \mathcal{L}_{logic}]$$

为什么有效:

- 将"被动惩罚结果"变为"主动引导去噪方向"
- 在零数据区域提供确定性梯度 (不是随机噪声)
- 双向约束防止过度保守 (全城低报) 或过度敏感 (全城高报)

退火策略:

前20epoch $\omega = 0$, 让模型先学习基本时空模式; 之后线性增加到1.0, 逐步引入逻辑约束。

2.2.4 稀疏犯罪传播图

问题: 动态图计算 $O(T \cdot N^2 \cdot \text{window})$, 当 $N=1246$ 时计算量过大

解决方案: 利用空间邻近性假设, 仅计算邻居间的高斯相似度

稀疏化策略:

$$A_{crime}^{sparse}[i, j] = \begin{cases} \exp(-\frac{\|c_i - c_j\|^2}{2\sigma^2}) & \text{if } A_{spatial}[i, j] > 0 \\ 0 & \text{otherwise} \end{cases}$$

计算复杂度:

- 稠密: $O(N^2) = O(1.5M)$
- 稀疏: $O(N \cdot k) = O(7.5K)$ (平均度 $k \approx 6$)
- 加速比: $\sim 200x$

物理合理性:

犯罪传播遵循距离衰减定律, 远距离 ($>1km$) 的犯罪相关性主要来自环境协变量而非真实传播。

2.3 扩散模型核心公式

前向扩散过程 (加噪):

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

反向去噪过程 (预测噪声):

$$p_{\theta}(x_{t-1}|x_t,c) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t,t,c), \Sigma_t)$$

训练目标:

$$\mathcal{L} = \mathbb{E}_{t,x_0,\epsilon} [\|\epsilon - \epsilon_{\theta}(x_t,t,c)\|^2] + \lambda_{zi}\mathcal{L}_{zi} + \lambda_{logic}\mathcal{L}_{logic}$$

其中:

- ϵ_{θ} : 神经网络预测的噪声
- $\mathcal{L}_{zi}$: 零膨胀损失 (BCE)
- $\mathcal{L}_{logic}$: 逻辑约束损失

三、运行步骤

3.1 完整运行流程

```
# =====
# Phase 1: 数据准备 (Data Preparation)
# =====

# 1. 下载犯罪数据 (分类下载: violent/Property)
python src/chicago_crime_downloader.py
# 输出: chicago_crime_data/cleaned/{violent,property}_{2022,2023}_cleaned.csv

# 2. 构建静态环境特征
python src/build_static_features.py
# 输出: data/processed/{poi,landuse,green,road,nightlight,camera}_features.npy

# 3. 构建OD流特征 (在另一台机器运行后传输)
python src/od_process/build_od_flow.py          # 生成日级OD
python src/od_process/grid_mapping.py          # 映射到1246网格
python src/od_process/merge_od_flow.py          # 合并为dynamic_od_flow.npy
# 输出: data/processed/dynamic_od_flow.npy (730, 1246, 4)

# 4. 构建犯罪时间序列
python src/build_crime_timeseries.py
# 输出: data/processed/crime_combined_timeseries.npy (730, 1246, 2)

# 5. 构建训练输入
python src/build_stgcn_input.py
# 输出: data/processed/X.npy, Y.npy

# 6. 构建所有图结构 (5张图)
python src/build_graph.py
# 输出:
#   - adj_adaptive.npy      (空间邻接)
#   - adj_distance.npy     (距离衰减)
#   - adj_crime_violent.npy (暴力传播)
#   - adj_crime_property.npy (财产传播)
#   - adj_od.npy           (OD功能相似)

# =====
# Phase 2: EP-STD 三阶段训练
# =====
```

```

# Stage 1: 环境编码器训练 (对比学习)
python src/epstd_stage1.py
# 输入: static_features (N, 24)
# 输出: checkpoints/env_encoder_best.pt, data/processed/env_embeddings.npy

# Stage 2: 原型学习 (K-Means + 模糊风险先验)
python src/epstd_stage2.py
# 输入: env_embeddings (N, 64)
# 输出: checkpoints/prototype_library.pkl, prototype_labels.npy

# Stage 3: 多图扩散模型训练 (核心)
python src/epstd_stage3_enhanced_multigraph.py
# 输入: X.npy, Y.npy, 5张图, env_embeddings, prototype_labels
# 输出: checkpoints/dual_multigraph_diffusion_best.pt

# =====
# Phase 3: 评估与应用
# =====

# 压力测试 (冷启动性能)
python experiments/masking_experiment.py
# 评估指标: MAE, Correlation, Hotspot Recall @ masked grids

# 策略推荐
python src/policy_recommender.py

# 可解释性分析
python src/explainability.py

```

3.2 快速复现 (使用已有检查点)

```

# 如果已有训练好的检查点, 直接预测
python -c "
from src.epstd_stage3_enhanced_multigraph import *

# 加载模型
model = load_model('checkpoints/dual_multigraph_diffusion_best.pt')

# 预测
predictor = MultiGraphPredictor(model, scheduler, adj_list, env_encoder,
                                prototype_library)
risk_mean, risk_std, pi = predictor.predict(X_test[0],
return_graph_weights=True)
"

```

3.3 文件依赖关系

```

build_static_features.py
↓
build_stgcn_input.py ← build_crime_timeseries.py ← chicago_crime_downloader.py
↓
epstd_stage1.py → env_embeddings.npy
↓
epstd_stage2.py → prototype_library.pkl
↓
epstd_stage3_enhanced_multigraph.py
↓
experiments/masking_experiment.py

```

3.4 关键检查点文件

文件	大小	说明
checkpoints/env_encoder_best.pt	~5MB	Stage 1环境编码器
checkpoints/prototype_library.pkl	~1MB	Stage 2原型库
checkpoints/multigraph_diffusion_best.pt	~50MB	Stage 3多图扩散模型
data/processed/X.npy	~170MB	训练特征 (723, 1246, 44)
data/processed/Y.npy	~3.5MB	训练标签 (723, 1246)

四、超参数配置

4.1 Stage 1 环境编码器

```

config_stage1 = {
    'input_dim': 24,           # 静态特征维度
    'hidden_dim': 128,
    'output_dim': 64,         # 环境嵌入维度
    'temperature': 0.07,      # InfoNCE温度系数
    'batch_size': 256,
    'epochs': 100,
    'lr': 1e-3
}

```

4.2 Stage 2 原型学习

```

config_stage2 = {
    'n_prototypes': 10,       # 原型数量（功能区类别）
    'fuzzy_threshold': 0.3,   # 模糊隶属度阈值
    'risk_bins': 5            # 风险分箱数
}

```

4.3 Stage 3 多图扩散

```

config_stage3 = {
    'hidden_dim': 128,

```



```
'num_layers': 4,           # 图注意力层数
'num_timesteps': 1000,     # 扩散步数
'beta_schedule': 'linear', # beta调度策略
'beta_start': 1e-4,
'beta_end': 0.02,
'graph_fusion_temp': 0.5,  # 图融合温度
'logic_warmup_epochs': 20, # 逻辑引导预热轮数
'guidance_scale': 1.0,     # 逻辑引导强度
'task_weights': {          # 多任务权重
    'violent': 1.0,
    'property': 0.5
}
}
```

五、性能指标预期

5.1 主要评估指标

指标	基线(STGCN)	EP-STD(无逻辑)	L-EPSTD(有逻辑)
MAE	2.5	2.1	1.8
Correlation	0.65	0.72	0.78
Hotspot Recall@10%	45%	58%	68%
Cold Start Recall	5%	25%	55%

5.2 消融实验设计

Ablation Study:

1. Base: 无环境编码 + 无逻辑引导
2. +Env: 加入环境编码器
3. +MultiGraph: 加入多图结构
4. +AdaptiveFusion: 加入自适应图融合
5. +CrossCrime: 加入双犯罪交叉反馈
6. +Logic: 加入T-Norm逻辑引导 (Full Model)

5.3 评估指标设计说明

为什么放弃传统指标 (RMSE/MAE/Hit Rate/PAI/Jaccard) ?

传统指标	问题	EP-STD替代方案
RMSE	对异常值敏感，零膨胀数据下会被大量零值主导	仅用于非零区域评估，配合零膨胀损失
MAE	无法区分"过度预测"和"预测不足"，警务部署中漏报代价更高	分位数损失 + 热点召回率组合
Hit Rate	只关心是否命中热点，不关心预测置信度	risk_std 不确定性量化
PAI	假设犯罪均匀分布，不适用于高度聚集的犯罪数据	原型内PAI（按功能区分组评估）
Jaccard	对空间边界敏感，网格微移会导致指标大幅波动	距离加权重叠度（考虑空间衰减）

核心差异：

- 零膨胀感知**：传统指标将零犯罪日视为普通样本，EP-STD使用零膨胀概率 `pi` 显式建模
- 不确定性量化**：传统指标点估计，EP-STD输出 `risk_std` 支持风险排序决策
- 冷启动评估**：传统指标在全数据上计算，EP-STD专门设计"屏蔽实验"评估冷启动网格
- 可解释性耦合**：传统指标黑盒，EP-STD指标与图权重、门控机制联动解释

六、模型输出与评估体系

6.1 基础预测输出

输出	符号	维度	说明
<code>risk_mean</code>	μ	(N,)	预测风险均值（期望犯罪数）
<code>risk_std</code>	σ	(N,)	预测不确定性（标准差）
<code>pi</code>	π	(N,)	零膨胀概率（该网格无犯罪的概率）
<code>graph_weights</code>	w	(B, N, 5)	5张图的自适应融合权重
<code>crime_gate</code>	g	(B, N, 2)	暴力/财产犯罪交叉门控权重

6.2 核心评估指标

6.2.1 冷启动专项指标（Masking Experiment）

<pre>{ 'mae': 0.15, 'correlation': 0.72, 'hotspot_recall': 0.65, 'n_masked': 249 }</pre>	<pre># 被屏蔽网格的平均绝对误差 # 预测与真实值的相关系数 # Top 10%热点召回率 # 被屏蔽网格数</pre>
--	---

6.2.2 全局性能指标

指标	含义	典型值	与传统指标对比
PAI@10%	预测准确度指数	1.5-2.5	相同计算方式，但仅在原型内计算
Recall@10%	热点召回率	55%-75%	等同于Hit Rate
Pearson r	整体相关性	0.65-0.85	等同于传统Correlation
Cold Start Recall	冷启动热点召回	25%-55%	传统指标无此细分

七、可解释性输出

7.1 多图自适应融合权重 (Adaptive Graph Fusion)

每个网格根据环境特征学习个性化的图融合权重，可解释该区域的主导影响因素：

```
# 网格123的图权重示例
{
  'Spatial': 0.03,      # 空间邻接图权重 - 低
  'Distance': 0.15,    # 距离衰减图权重 - 中
  'CrimeV': 0.05,      # 暴力犯罪传播图 - 低
  'CrimeP': 0.75,      # 财产犯罪传播图 - 高（主导）
  'OD': 0.02           # OD流功能相似图 - 低
}
```

可解释性解读：

- 高Spatial权重 → 居民区（近邻效应主导）
- 高OD权重 → 商业区/交通枢纽（人流驱动犯罪）
- 高CrimeV权重 → 高风险区（历史暴力犯罪聚集）
- 高CrimeP权重 → 商业密集区（盗窃抢劫高发）

7.2 交叉犯罪门控 (Cross-Crime Gate)

```
{
  'violent_weight': 0.30, # 暴力犯罪图贡献
  'property_weight': 0.70 # 财产犯罪图贡献
}
```

可解释性解读：

- 当暴力犯罪数据稀疏时（冷启动），门控自动提高财产犯罪图权重进行"迁移学习"
- 财产犯罪与暴力犯罪在空间分布上存在相关性（商业区两者都高）
- 门控机制允许模型学习"何时依赖哪种犯罪类型"

7.3 原型聚类解释 (Stage 2)

原型ID	网格数	平均风险	功能区类型	特征描述
0	145	0.186	高密度商业区	商业POI密集、人流大
1	14	0.571	夜间娱乐区	酒吧夜店聚集
4	25	0.860	高风险商业区	商业+低监护
6	780	0.076	低密度住宅区	安静居住区
9	96	1.026	交通枢纽区	车站+商业混合

7.4 扩散过程可视化

- **去噪轨迹图**：展示从纯噪声到最终风险预测的全过程
- **时间注意力热图**：不同时间步的注意力权重分布（近重复效应窗口）
- **环境-原型映射**：T-SNE可视化环境嵌入空间中的原型分布

八、政策建议生成系统

8.1 网格风险画像

系统为每个高风险网格生成结构化画像：

```
GridProfile {
  grid_id: 123,
  risk_score: 0.85,           # 预测风险分数
  risk_level: '极高',        # 风险等级（极高/高/中/低）
  cpted_scores: {            # CPTED四维评估
    'natural_surveillance': 0.2, # 自然监护不足
    'access_control': 0.3,       # 入口控制薄弱
    'territorial_reinforcement': 0.2,
    'target_hardening': 0.1
  },
  environmental_features: {
    'green_ratio': 0.7,         # 绿化率高（可能遮挡视线）
    'nightlight': 0.2,         # 夜间照明不足
    'camera_count': 0.1        # 摄像头覆盖率低
  },
  nearby_crimes_7d: 3          # 近7天周边犯罪数
}
```

8.2 分级干预措施

立即执行（24小时内）

措施	优先级	成本	实施主体	预期效果
启动近重复预警响应	极高	低	公安分局	案发后7天内周边犯罪率降30%
增加定点巡逻	高	低	辖区派出所	提升见警率，震慑潜在犯罪
推广社区守望计划	高	低	社区居委会	建立商户居民即时通报机制

短期措施（1周内）

措施	优先级	成本	实施细节
升级LED路灯	高	中	更换为200W LED，照度提升至50lux以上
增补AI智能摄像头	高	中	在网格四角安装行为识别摄像头
修剪植被高度	高	低	灌木修剪至0.6米以下，树枝至2.5米以上
封闭无用巷道	高	中	用铁栅栏封闭犯罪高发的小巷和捷径

中期措施（1月内）

措施	优先级	成本	预期效果
引入便民商业	中	中	税收优惠吸引便利店入驻，增加自然监护
举办社区活动	中	低	周末集市、文艺演出，增加正当人流
增设口袋公园	中	高	利用闲置空地建设小型公园

8.3 巡逻部署方案

```
{
  'total_officers_deployed': 10,
  'coverage_grids': 15,
  'shift_recommendation': '三班制(06:00-14:00, 14:00-22:00, 22:00-06:00)',
  'grid_assignments': [
    {
      'grid_id': 123,
      'officers_assigned': 2,
      'patrol_hours': ['20:00-02:00'], # 高风险时段
      'patrol_mode': '步行巡逻', # 道路密度高
      'focus_areas': ['商业街区出入口', '监控盲区', '公交站点']
    }
  ]
}
```

8.4 预算估算

```
{
  'immediate_usd': 5000, # 立即行动（警力调度）
  'short_term_usd': 150000, # 短期措施（照明、摄像头）
  'medium_term_usd': 300000, # 中期措施（基础设施）
  'total_usd': 455000,
  'manpower_priority': '高',
  'roi_estimate': '每投入$1可降低犯罪损失$3-5'
}
```

九、城市设计建议（按功能区）

9.1 高密度商业区

典型特征：CrimeP权重高、商业POI密集、人流混杂

问题诊断	设计建议	责任主体
犯罪目标丰富	推广商铺卷帘门、入侵报警器补贴	商务局+公安
人流混杂	建立50米范围商户联防机制	街道办
便于逃离	优化路口布局，减少潜在逃逸路径	规划局

9.2 低密度住宅区

典型特征：Spatial权重高、CPTED监护评分低

问题诊断	设计建议	责任主体
自然监护不足	组织社区守望计划微信群	社区居委会
照明死角	安装太阳能感应灯	城管局
门禁管理松懈	修复损坏单元门，加装闭门器	物业公司

9.3 交通枢纽区

典型特征：OD权重高、人流密集

问题诊断	设计建议	责任主体
站内摄像头盲区	优化摄像头布局，接入公安平台	交通局+公安
人员徘徊	设置清晰的方向指示系统	地铁公司
夜间疏散难	增加出租车/网约车接驳点	交通局

文档结束